

PYTHON

Présenté par :
Xavier TABUTEAU

Pandas

Pandas

• Introduction

Pandas est une bibliothèque Python open source conçue pour la manipulation et l'analyse de données. Elle repose sur NumPy (pour la gestion des tableaux) et fournit des structures de données flexibles et puissantes.

Deux structures de base :

- Series : Vecteur 1D avec des étiquettes (index).
- DataFrame : Tableau 2D avec lignes et colonnes étiquetées.

Pandas est particulièrement utilisé en science des données, finance, statistiques, apprentissage automatique, big data.

Pandas

Pandas

- **La structure Series**

Une « Series » est un tableau à une dimension étiqueté :

- Elle peut contenir des nombres, chaînes, booléens, objets, etc.
- Elle est semblable à un tableau de NumPy, mais avec un index personnalisé.

Exemple :

Index	0	1	2	3
Valeur	10	20	30	40

Caractéristiques :

- Indexation rapide (par position ou étiquette).
- Supporte les opérations vectorisées (comme NumPy).
- Manipulation facile des données manquantes (NaN).

Pandas

Pandas

- **La structure DataFrame**

Un « DataFrame » est la structure centrale de Pandas :

- Tableau 2D de données (semblable à une feuille Excel ou une table SQL).
- Lignes indexées + colonnes nommées.
- Chaque colonne est une « Series ».

Exemple :

	Nom	Age	Ville
0	Alice	25	Paris
1	Bob	30	Londres
2	Charlie	35	Berlin

Caractéristiques :

- Colonnes de types différents (int, float, string, etc.).
- Accès aux données par indexation, étiquettes ou conditions.
- Support de données hétérogènes et données manquantes.

Pandas

Pandas

• Fonctions principales de Pandas

Chargement et enregistrement des données :

- `read_csv()`, `read_excel()`, `read_sql()`, `read_json()` : importer des données.
- `to_csv()`, `to_excel()`, `to_sql()` : exporter des données.

Exploration et manipulation :

- Aperçu rapide : `head()`, `tail()`, `info()`, `describe()`.
- Sélection : `loc[]` (par étiquettes), `iloc[]` (par positions).
- Filtrage par conditions : `(df[df["col"] > 10])`.
- Tri : `(sort_values())`.

Opérations sur les colonnes :

- Ajout, suppression : `df["col_nouvelle"] = ...`, `drop()`.
- Statistiques : `mean()`, `sum()`, `max()`, `min()`.
- Regroupement : `groupby()`.
- Fusion/jointure : `merge()`, `concat()`, `join()`.

Gestion des données manquantes :

- `isna()`, `fillna()`, `dropna()`.

Pandas

`pandas.py`

Pandas

• Applications typiques de Pandas

- Analyse exploratoire de données (EDA).
- Nettoyage et préparation des données (traitement des valeurs manquantes, transformation).
- Agrégation et regroupement (ex. calculer une moyenne par groupe).
- Jointure de plusieurs sources de données.
- Exportation vers Excel, SQL, JSON, CSV.
- Manipulation de séries temporelles (dates, fréquences, rééchantillonnage).

Avantages :

- Très puissant pour les données tabulaires.
- Syntaxe claire et expressive.
- Compatible avec NumPy, Matplotlib, Scikit-learn.
- Large communauté et documentation.


Limites :

- Peut être lent avec de très gros jeux de données (RAM limitée).
- Pas adapté au calcul distribué → dans ce cas, on utilise Dask ou PySpark.
- Courbe d'apprentissage pour bien maîtriser toutes ses fonctionnalités.

Conclusion :

- Pandas est un outil incontournable pour toute personne travaillant avec des données en Python.
- Il combine la simplicité d'Excel avec la puissance de SQL et la flexibilité de Python.

PYTHON



Présenté par
Xavier TABUTEAU